Detecção de fraudes com Random Forest

Relatório técnico do Checkpoint 1 | Grupo 3 | Preparação em 20/10/2026

O primeiro fluxo foi executado: auditoria da base, preparação, treinamento, avaliação na validação e previsão de novas linhas. O Random Forest identificou 80 das 94 fraudes da validação, com 15 falsos alertas. A configuração é preliminar e o conjunto de teste permanece reservado.

Problema e pergunta de investigação

Como apoiar a triagem de transações potencialmente fraudulentas sem produzir excesso de alertas falsos? Investigamos se a combinação de árvores em Random Forest melhora a identificação de fraudes em relação a uma Árvore de Decisão, considerando precisão, recall e F1, e não apenas acurácia.

O público previsto são equipes de prevenção a fraudes. O produto acadêmico recebe atributos de uma transação no formato da base e retorna uma classificação e um score para apoiar inspeção humana. Não autoriza bloqueios automáticos.

Dataset e auditoria

A base Credit Card Fraud Detection [4], produzida na colaboração ULB/Worldline, contém transações de titulares europeus de dois dias de setembro de 2013. V1 a V28 são componentes de PCA já fornecidos, sem significados originais disponíveis. Time representa segundos desde a primeira transação; Amount é o valor; Class é o alvo (0 normal e 1 fraude).

Verificação	Resultado observado
Base original	284.807 registros; 31 colunas; 30 entradas e 1 alvo
Classes originais	284.315 normais e 492 fraudes (0,1727%)
Ausentes e não finitos	Nenhum ausente ou valor infinito encontrado
Duplicados completos	1.081 cópias adicionais: 1.062 normais e 19 fraudes
Base após deduplicação	283.726 registros: 283.253 normais e 473 fraudes

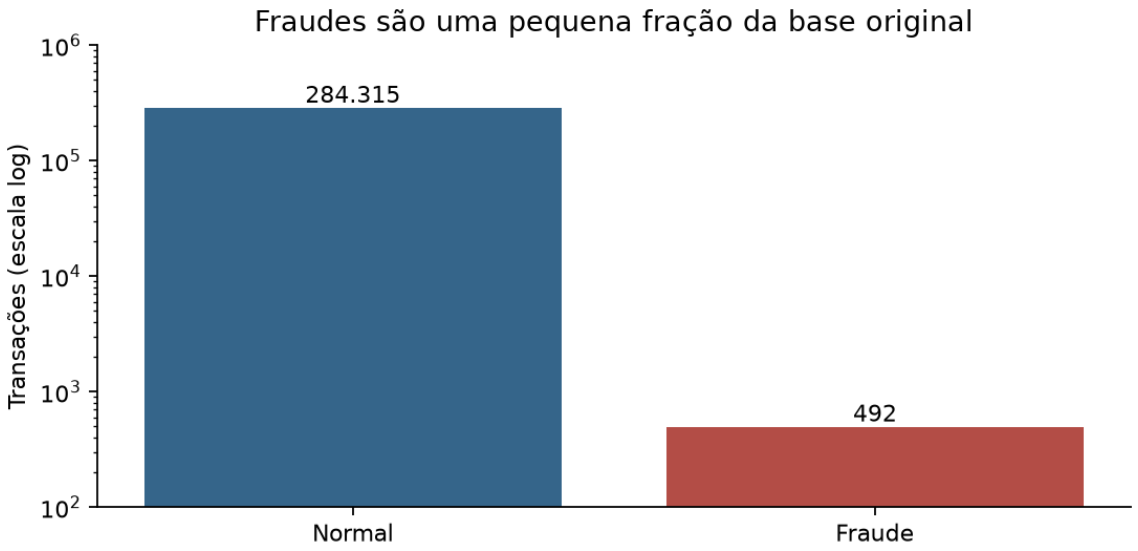
Separação antes dos modelos

Conjunto	Registros	Fraudes
Treino	170.235	284
Validacao	56.745	94
Teste	56.746	95

Divisão estratificada 60/20/20, random_state=42. A EDA detalhada usa somente o treino; a validação recebe a comparação preliminar; o teste não foi avaliado. Identificadores das linhas e hashes das entradas são disjuntos entre conjuntos.

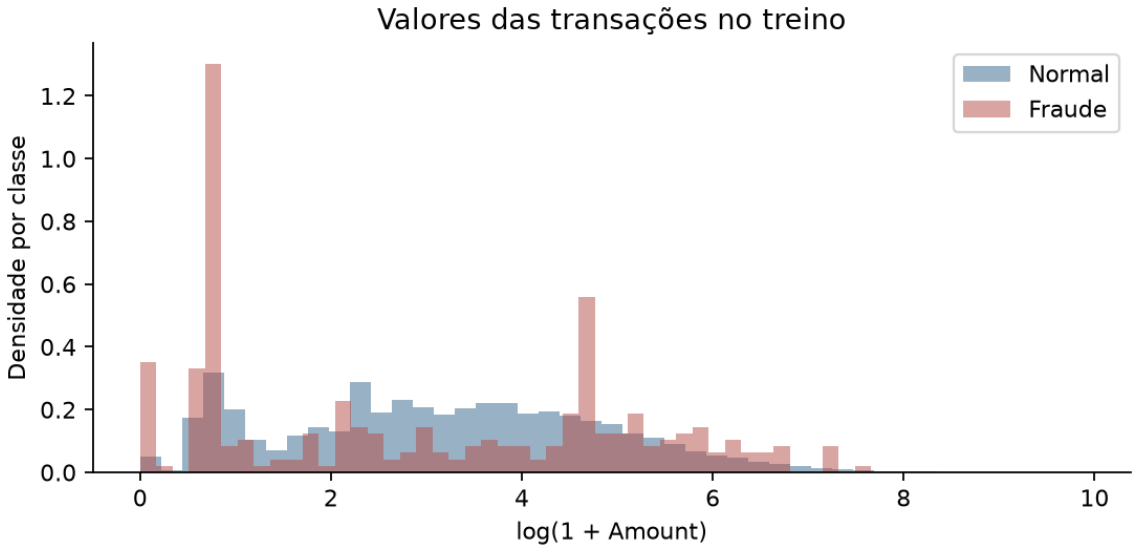
Descobertas da análise exploratória

Fraude é rara na base original



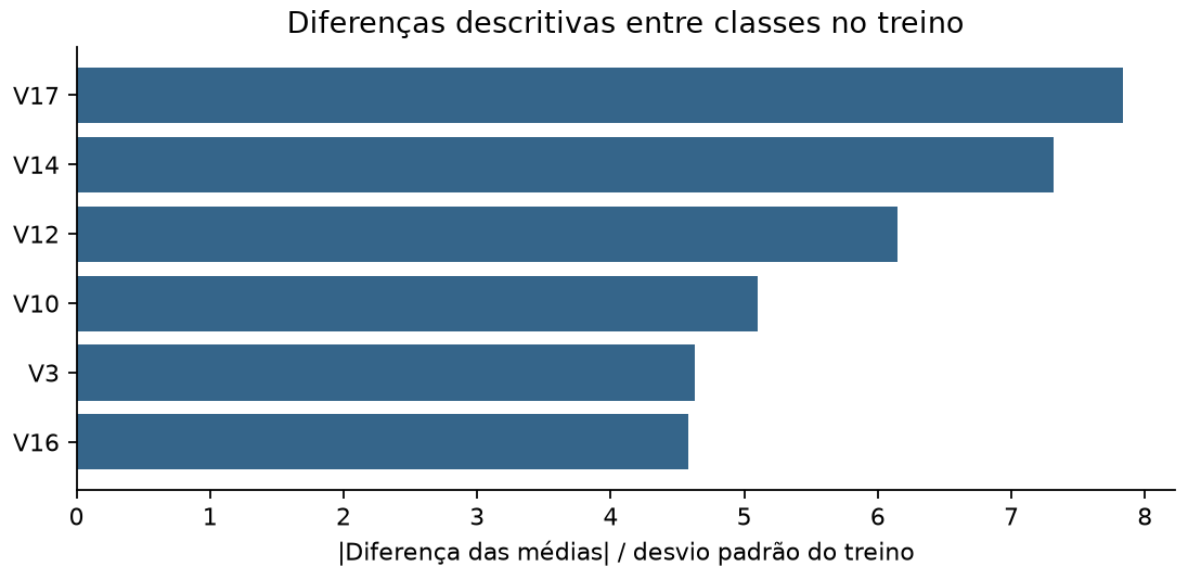
Descoberta 1: só 492 de 284.807 transações são fraudes. Um classificador que responde sempre normal acerta aproximadamente 99,83% na base original sem identificar uma única fraude. Por isso, a acurácia isolada não atende ao objetivo.

Transações fraudulentas não são sempre as mais caras



Descoberta 2: no treino, a mediana de Amount foi 11,855 para fraudes e 22,05 para normais. As médias foram 118,87 e 88,11, respectivamente. A diferença entre média e mediana e a sobreposição das distribuições mostram que um limiar de valor, sozinho, não caracteriza fraude. Os valores estão na unidade monetária da base; não foram convertidos para reais.

Variáveis e qualidade dos dados



Descoberta 3: V17, V14 e V12 apresentaram as maiores diferenças absolutas entre médias das classes, padronizadas pelo desvio do treino: 7,83; 7,32; 6,14. Isso sugere sinais discriminativos para investigar. A estatística é descritiva: não demonstra causalidade nem garante desempenho de uma variável isolada.

Relações entre entradas

No treino, o maior módulo de correlação de Pearson entre entradas foi entre V2 e Amount (r = -0,539). Correlação descreve associação linear e não permite atribuir um significado comercial ao componente V2. A tabela completa está em results/correlacoes_treino.csv.

Extremos e escala

Os limites de 1,5 vez o intervalo interquartil foram calculados apenas no treino. Amount possui cauda longa, inclusive em transações normais; o maior Amount normal no treino foi 19.656,53, enquanto o maior fraudulento foi 2.125,87. Valores extremos foram preservados, pois podem representar eventos legítimos ou sinais de fraude. Um sinalizador estatístico de extremo não é um rótulo de fraude.

Não há entradas categóricas para codificar. A normalização foi considerada e não aplicada: os dois classificadores utilizados particionam cada variável por limiares e não dependem de distância entre escalas. Não foi aplicada nova PCA, imputação, SMOTE, remoção por outliers ou seleção de variáveis nesta etapa.

Limpeza e prevenção de vazamento

Removemos somente cópias integralmente idênticas, mantendo a primeira ocorrência antes da separação. A medida evita que a mesma entrada seja vista no treino e na avaliação. Sem identificadores, não é possível provar se cada repetição seria um evento distinto; por isso a deduplicação é uma decisão conservadora, documentada e reproduzível.

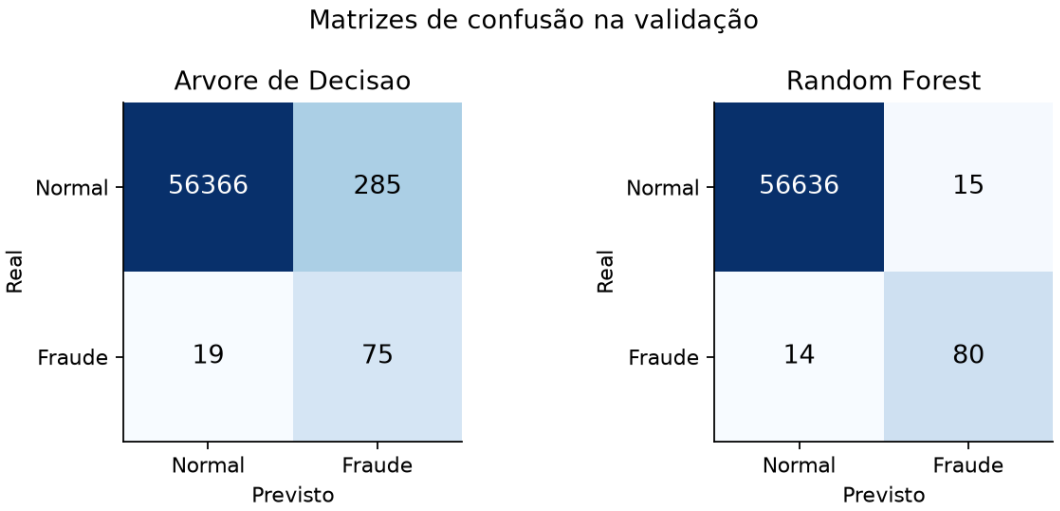
Class não entra no modelo. As classes originais são preservadas na validação e no teste. Os pesos de classe são calculados pelo estimador apenas com o treino. O escopo de ajuste da PCA original não é informado na distribuição pública; esse limite impede garantir toda a independência da transformação realizada pelos autores.

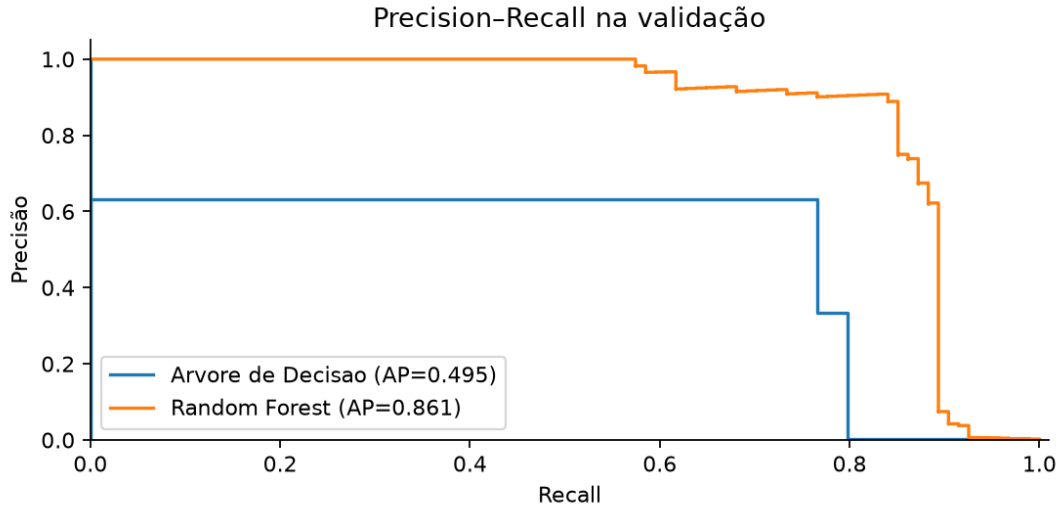
Modelos e resultados preliminares

A Árvore de Decisão é o baseline por permitir comparar uma árvore com uma floresta [1,5]. Ambos usam max_depth=12, min_samples_leaf=2, class_weight=balanced e random_state=42. A floresta usa 100 árvores, bootstrap e max_features=sqrt, com n_jobs=4. Esses parâmetros iniciais não foram escolhidos por busca no teste.

Modelo	Precisão	Recall	F1	AP
Sempre normal	0,00%	0,00%	0.0000	0.0017
Arvore de Decisao	20,83%	79,79%	0.3304	0.4948
Random Forest	84,21%	85,11%	0.8466	0.8611

Avaliação: validação com 56.745 transações, sendo 94 fraudes. Positivo = fraude. Limiar da floresta = 0,5. AP é Average Precision, resumo da curva Precision-Recall calculado por average_precision_score; não é tratado como área trapezoidal idêntica. A análise de classes raras é apoiada por Saito e Rehmsmeier [2].





A árvore encontrou 75 fraudes e deixou passar 19, com 285 falsos positivos. A floresta encontrou 80 e deixou passar 14, com 15 falsos positivos. Nessa divisão e configuração, a floresta teve melhor precisão e recall; não foi feita análise de incerteza ou validação temporal, portanto o resultado não estabelece superioridade universal.

Erros e próxima investigação

A inspeção usa casos reais da validação. Linha original é o índice de leitura do CSV, começando em zero. As causas dos erros ainda são hipóteses; a anonimização impede reconstruir o contexto real da compra.

Linha	Caso	Evidência e interpretação
74794	Falso negativo	Fraude, Amount 311,91, score 0,0299. O modelo deixou passar a fraude com score baixo. Investigar semelhança com padrões normais e representatividade no treino.
50537	Falso negativo	Fraude, Amount 1,00, score 0,000365. Exemplo concreto de fraude de baixo valor; valor alto não pode ser o único critério de suspeita.
175549	Falso positivo	Normal, Amount 37,93, score 0,5067. Caso próximo do limiar de 0,5. Uma análise de limiar poderá estudar o custo de sinalizar transações legítimas.

Três experimentos planejados para o próximo checkpoint

As hipóteses abaixo foram registradas antes de executar esses novos experimentos. A comparação inicial entre modelos já ocorreu; os três testes abaixo ainda não foram executados.

Exp.	Hipótese e alteração controlada
E1	Pesos balanced podem aumentar o recall, com custo em falsos alertas. Comparar class_weight=None versus balanced na floresta, mantendo os outros parâmetros e a divisão.
E2	Maior profundidade pode elevar o ajuste ao treino sem melhorar a validação. Comparar max_depth=6, 12 e None; manter as outras configurações. Registrar métricas de treino e validação.
E3	Remover os cinco componentes com maior diferença entre classes no treino pode reduzir recall e AP. Comparar as 30 entradas com a versão sem V17, V14, V12, V10 e V3, mantendo o restante.

Em todos: registrar precisão, recall, F1, AP, falsos positivos, falsos negativos e tempo; interpretar ganhos e custos. Usar a mesma validação, sem consultar o teste para selecionar parâmetros. Após fechar as decisões, avaliar uma vez no teste reservado.

Limitações

São apenas dois dias de dados de 2013, poucas fraudes e entradas anonimizadas. A separação aleatória não mede generalização futura nem garante separação por titular, pois faltam identificadores. Não houve calibração dos scores, ajuste de limiar, validação temporal ou estimativa de incerteza. A importância por impureza salva é exploratória e não fornece uma explicação causal da compra.

Reprodução e demonstração

Ambiente executado: Python 3.12.14, pandas 3.0.1, numpy 2.5.4, scikit-learn 1.9.1, matplotlib 3.11.2 e joblib 1.6.0. As versões estão fixadas em requirements.txt.

Na raiz do projeto: criar ambiente virtual, instalar requirements.txt, executar python src/baixar_dados.py, depois python src/pipeline.py e python src/prever.py. O arquivo EXECUTAR.ps1 reúne esses passos no Windows. O dataset completo não é enviado ao Git; o script verifica seu SHA-256.

Resultados já gerados estão em results/. A previsão de demonstração usa dez transações da validação, sem Class no arquivo de entrada. O gabarito é separado. Uma nova entrada precisa fornecer as 30 colunas no formato ULB; cidade, loja e número de parcelas não estão disponíveis. O protótipo web completo pertence à etapa seguinte.

Roteiro de dez minutos

Tempo	Evidência
0 a 2 min	Problema, público e pergunta de comparação.
2 a 4 min	Três descobertas: desbalanceamento, valores e componentes.
4 a 6 min	Comparar as métricas e explicar um falso positivo e um falso negativo.
6 a 8 min	Executar src/prever.py; mostrar comando de reprodução do pipeline.
8 a 10 min	Apresentar os três experimentos planejados e as limitações.

Referências selecionadas

[1] BREIMAN, L. Random Forests. Machine Learning, v. 45, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.

[2] SAITO, T.; REHMSMEIER, M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, v. 10, n. 3, e0118432, 2015. DOI: 10.1371/journal.pone.0118432.

[3] DAL POZZOLO, A.; CAELEN, O.; LE BORGNE, Y.-A.; WATERSCHOOT, S.; BONTEMPI, G. Learned lessons in credit card fraud detection from a practitioner perspective. Expert Systems with Applications, v. 41, n. 10, p. 4915-4928, 2014. DOI: 10.1016/j.eswa.2014.02.026.

[4] MACHINE LEARNING GROUP - ULB; WORLDLINE. Credit Card Fraud Detection. Kaggle. Base de transações de setembro de 2013. Acesso em: 20 out. 2026.

[5] SCIKIT-LEARN DEVELOPERS. RandomForestClassifier. Documentação oficial. Versão executada: 1.9.1. Acesso em: 20 out. 2026.

[6] SCIKIT-LEARN DEVELOPERS. Common pitfalls and recommended practices. Documentação oficial. Acesso em: 20 out. 2026.